


Jan Kaczmarecki Raport lab0

Pipeline



Prosty pipeline z wyświetlaniem danych z datasetu, wyborem kolumn, preprocessingiem, treningiem i oceną wpływu cech na otrzymany wynik.

Regresja Logistyczna vs Drzewa decyzyjne

Evaluation results for target (None, show average over classes) ▼							
Model	AUC	CA	F1	Prec	Recall	MCC	
Tree	0.997	0.949	0.948	0.950	0.949	0.930	
Logistic Regression	0.884	0.696	0.671	0.655	0.696	0.578	

Jak można zobaczyć drzewa decyzyjne osiągnęły znacznie lepszy wynik niż regresja logistyczna. Wynik można powiedzieć że jest praktycznie idealny. Może to jednak oznaczać, że nasz model jest za przeuczony i nauczył się szumu, a nie tyle co klasyfikacji. Wpływ na taki wynik może też mieć rozmiar zbioru danych (214 wpisów) przez co może on nie pokrywać wszystkich zależności. Regresja logistyczna ma bardzo mały Prec i Recall na poziomie ~0.7 - pokazuje on znacznie gorsza wydajność.

Najlepsze i najgorsze cechy

Scoring Methods			#	Gain ratio ▾	Gini
☐	Information Gain		1	0.402	0.107
☒	Information Gain Ratio		2	0.269	0.101
☒	Gini Decrease		3	0.236	0.121
☐	ANOVA		4	0.184	0.080
☐	χ^2		5	0.165	0.073
☐	ReliefF		6	0.163	0.074
☐	FCBF		7	0.098	0.034
			8	0.086	0.022
			9	0.073	0.031

Jak można zobaczyć za pomocą "Rank" najlepsze Information Gain daje nam: Ba, Mg i Al. Za to 3 najmniej znaczące wartości które nie wnoszą wartości do naszego modelu, a raczej szum to Rb, Fe oraz Si. Wartości tych 3 pierwiastków odbiegają znacząco od innych featerów regresji. Różnicę między najlepszymi i najgorszymi cechami to odpowiednio:

- $\max(\text{gain_ratio}) - \min(\text{gain_ratio}) = 0,329$

Regresja

1. Na jako wartość wyliczana

☒ Cross validation	
Number of folds: 5	
☒ Stratified	
☐ Cross validation by feature	
☐ Random sampling	
Repeat train/test: 10	
Training set size: 66 %	
☒ Stratified	
☐ Leave one out	
☐ Test on train data	
☐ Test on test data	

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Tree	0.399	0.631	0.396	2.949	2.955	0.400
Linear Regression	0.012	0.108	0.078	0.594	0.592	0.982

2. Ba jako wartość wyliczana

☒ Cross validation	
Number of folds: 5	
☒ Stratified	
☐ Cross validation by feature	
☐ Random sampling	
Repeat train/test: 10	
Training set size: 66 %	
☒ Stratified	
☐ Leave one out	
☐ Test on train data	
☐ Test on test data	

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Tree	0.192	0.438	0.136	inf	41.161	0.220
Linear Regression	0.010	0.102	0.075	inf	168.971	0.958

3. Mg jako wartość wyliczana

☒ Cross validation	
Number of folds: 5	
☒ Stratified	
☐ Cross validation by feature	
☐ Random sampling	
Repeat train/test: 10	
Training set size: 66 %	
☒ Stratified	
☐ Leave one out	
☐ Test on train data	
☐ Test on test data	

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Tree	0.670	0.819	0.440	inf	31.598	0.676
Linear Regression	0.011	0.105	0.076	inf	41.340	0.995

4. Al jako wartość wyliczana

☒ Cross validation	
Number of folds: 5	
☒ Stratified	
☐ Cross validation by feature	
☐ Random sampling	
Repeat train/test: 10	
Training set size: 66 %	
☒ Stratified	
☐ Leave one out	
☐ Test on train data	
☐ Test on test data	

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Tree	0.150	0.387	0.249	20.629	18.581	0.395
Linear Regression	0.011	0.105	0.074	6.061	5.765	0.955

Wnioski

- **R²** mówi nam jak dobrze nasz model jest w stanie przewidzieć (regresja) wartość jednego feature na podstawie pozostałych. W przypadku dataset "Glass" jest to na przykład wskaźnik jak dobrze przewidzieliśmy wartość Na w szkle jeśli pozostałych pierwiastków (Ba, Al, ...) jest konkretna ilość.
 - Jeśli R² jest bliskie 1, to nasz model bardzo dobrze przewidyuje tą wartość
 - Jeśli R² jest równe 0, to model nie wykazuje żadnych zależności i jego przewidywania są tak samo dokładne, jak zwykłe uśrednienie wyników z danych.

- Jeśli R^2 jest < 0 to model działa gorzej niż naiwne przewidywanie po prostu średniej wartości.
- **Kolinearność** mówi nam jak bardzo cechy są ze sobą powiązane. W naszym przypadku jeśli regresja liniowa ma R^2 na poziomie 0,995 dla Mg to oznacza to, że z bardzo dużą dokładnością jesteśmy w stanie wyznaczyć wartość Mg w oparciu o inne parametry modelu. Oznacza to, że Mg jest kolinearne z innymi parametrami.
- **Redundantna informacja** oznacza to informację które jest “powtarzalna” czyli może być wywnioskowane z innych wartości innych parametrów. W przypadku dataset “Glass” taką redundantną informacją jest na przykład Mg.