



Jan Kaczmariski PUM lab 2

Zadanie 1



Na wykresie t-sne widać, że klasy wykazują stosunkowo dobrą separację. Można zauważyć 2 główne skupiska dla klas Healthy i AML. Występują jednak miejsca zarówno w klasie AML i Healthy które nie pozwalają na idealną separację danych za pomocą klasyfikatora liniowego. Plusem jest to, że zbiór nie jest samym szumem ale można w nim znaleźć zależności.


Odległość między próbkami - Histogram



Analiza histogramu pozwala stwierdzić, że przy dużym wymiarze $N=1000$ próbki dążą do tej samej odległości między nimi czyli około 20-30. Sprawia to, że klasyczne algorytmy oparte o np. miarę euklidesową stają się bezużyteczne bo np. warunek najbliższego sąsiada spełnia go niemal cała reszta zbioru. Pokazuje to, że w przy dużym wymiarze danych musimy często używać innych algorytmów bo podstawowe mogą nie działać poprawnie.

Zadanie 2

Podstawowe MLP przed skalowaniem



Cross validation

Number of folds: 5

☒ Stratified

☐ Cross validation by feature

☒ Replicate

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out


☐ Test on train data

☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
SVM	0.970	0.922	0.922	0.923	0.922	0.845
Tree	0.957	0.952	0.952	0.952	0.952	0.904
Neural Network	0.916	0.904	0.904	0.905	0.904	0.808

MLP po skalowaniu



Cross validation

Number of folds: 5

☒ Stratified

☐ Cross validation by feature

☒ Replicate

☐ Random sampling

Repeat train/test: 10

Training set size: 66 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☐ Test on test data

Evaluation results for target (None, show average over classes)


Model	AUC	CA	F1	Prec	Recall	MCC
SVM	0.970	0.922	0.922	0.923	0.922	0.845
Tree	0.957	0.952	0.952	0.952	0.952	0.904
Neural Network	0.957	0.942	0.942	0.943	0.942	0.884

Wnioski

Jak można zobaczyć przed optymalizacją sieci neuronowej MLP miała ona gorsze wyniki niż podstawowe klasyfikatory jak Tree albo SVM. Jest to spowodowane przez 2 parametry: liczbę neuronów w warstwie (100) oraz **bardzo** słabą regularyzację na poziomie $\alpha=0.0001$. Powodowało to, że model się przeuczał (100 neuronów w sieci), a słaba regularyzacja nie penalizowała tych dużych wag modelu.

Jeśli spojrzymy na model zoptymalizowany, czyli 50 neuronów w sieci i mocna regularyzacja na poziomie $\alpha=2$, to zobaczymy poprawę wyników z $AUC=0.916$ i $CA=0.904$ na $AUC=0.957$ i $CA=0.942$. Te wyniki znacznie poprawiają jakość modelu.


Wpływ ilości warstw na wyniki MLP



Configuration: Cross validation, Number of folds: 5, Stratified, Cross validation by feature: Replicate, Repeat train/test: 10, Training set size: 66 %, Stratified, Leave one out, Test on train data, Test on test data.

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
SVM	0.970	0.922	0.922	0.923	0.922	0.845
Tree	0.957	0.952	0.952	0.952	0.952	0.904
Neural Network	0.907	0.909	0.909	0.912	0.909	0.821



Neural Network

Name: Neural Network

Neurons in hidden layers: 50,50,50

Activation: ReLu

Solver: Adam

Regularization, $\alpha=2$: [slider]

Maximal number of iterations: 200

☒ Replicable training

Buttons: Cancel, ☒ Apply Automatically

Jak można zobaczyć zwiększenie capacity naszego klasyfikatora MLP z zachowaniem regularyzacji na poziomie $\alpha=2$ znacznie pogorszyło jakość modelu. Spadła ona na poziom $AUC=0.907$ z poprzedniego progu 0.957 oraz $CA=0.909$ z poprzedniego progu $CA=0.942$. Pokazują to, że nasz model jest w stanie podzielić dane (shatter) w większym stopniu czyli nauczyć się ich na pamięć. Skutkuje to over fittingiem modelu.